

オンプレミスで実現する 生成AI

プライベート環境におけるセキュリティとコスト最適化

製造業・インターネット非接続工場ネットワーク向け戦略案

DX推進部 | 2024年5月

本日の議題 (Agenda)



1. 背景と課題

現状の課題分析



2. オンプレ LLM

定義と構造



3. 利点・欠点

詳細な比較



4. 導入ケース

具体シナリオ



5. 実装ステッ



6. コスト管理



7. まとめ

導入背景と解決すべき課題

製造業特有の制約

- 🛡️ **機密保持:** 設計データや営業秘密を外部クラウドへ送信不可。
- 🔌 **非接続環境:** インターネットから隔離された工場内ネットワーク環境。
- 🔄 **システム統合:** 既存のERP/PLMとのセキュアな直接連携が必要。



オンプレミスLLMの定義

システム概要

自社管理のGPU/CPU環境にデプロイする大規模言語モデル。データの主権を完全に保持し、推論処理をクローズドな環境で完結させます。

代表的なオープンソースモデル

- Llama 3 (Meta)
- Mistral / Mixtral
- Command R (Cohere)

技術アーキテクチャ

Infrastructure: Bare-metal GPU servers / NVIDIA DGX

Orchestration: Kubernetes, Docker Container

Serving Tool: vLLM, Text Generation Inference (TGI)

※社内専用APIとしてサービス化が可能

メリットとデメリット

+ メリット

- **データ流出防止:** 全データが社内ネット内で完結。
- **自由な調整:** 独自データでの微調整(FT)が可能。
- **固定コスト:** 従量課金がなく、高頻度利用で割安。
- **超低遅延:** 内部LAN接続による高速レスポンス。

- デメリット

- **初期投資:** 高価なGPUサーバー等のハードウェア費用。
- **運用負荷:** 冷却、電力、物理メンテナンスの必要性。
- **更新難度:** 最新モデルへの追従にエンジニア工数。
- **スペック固定:** 急激な負荷増へのスケールに時間を要す。

指標: NVIDIA A100 (8枚構成) 導入で約2,500万円～ + 電気代・人件費

クラウドLLMとの詳細比較

評価項目	オンプレミスLLM	クラウドLLM (API型)
セキュリティ	最高レベル (完全閉域)	提供元の信頼性に依存
データ活用	社内秘匿データを無制限に利用可	機密データの送信には制限あり
コスト構造	CAPEX (初期投資) 型・固定費	OPEX (従量課金) 型・変動費
運用負荷	高い (ハード・インフラ管理必要)	低い (マネージドサービス)
スケーラビリティ	ハードウェア増設が必要	即時に拡張可能

機密性が最優先される環境では**オンプレミス一択**、汎用的な利用にはクラウドが適しています。

具体的導入シナリオ



金融: 機密分析

1. 顧客取引データの抽出
2. 匿名化处理なしで推論
3. 不正検知・リスク分析
4. 内部レポート自動生成



製造: CAD/PLM


1. 過去の設計図面データ取得
2. 技術仕様書の前処理
3. 設計支援AIが回答提示
4. ベテラン技術のナレッジ化



医療: 診断支援

1. 患者の電子カルテ読み込み
2. 医学論文DBとの照合
3. 診断候補・処方の提示
4. PII（個人情報）を保護

実装ステップとタイムライン



想定期間: 6ヶ月 ~ 1年 (PoC期間を含む)

コスト分析と投資対効果 (ROI)

初期投資 (CAPEX)

サーバー・GPU: 約2,500万円

年間運用費 (OPEX)

電力・保守・冷却: 約500万円

$$\text{ROI 算出式: } \text{ROI} = \frac{(\text{節約コスト} - \text{初期投資})}{\text{初期投資}}$$

※API課金コストの回避、作業時間短縮による人的コスト削減により、3年以内の回収を目標とします。

まとめと次のアクション

- ✔ **活用価値:** 知的財産の完全保護と非接続環境での業務変革。
- ✔ **重要ポイント:** 適切なハードウェアスペックの見極めと、データの整備。
- ✔ **ロードマップ:** Pilot (3ヶ月) → Production (6ヶ月) → 全社スケール。

ご清聴ありがとうございました。

| Image Sources



https://static.vecteezy.com/system/resources/previews/059/525/274/large_2x/data-center-cool-blue-glow-of-server-racks-photo.jpg

Source: www.vecteezy.com



<https://images.presentationgo.com/2025/04/neural-network-connections-illustration.jpg>

Source: www.presentationgo.com