

5月 27, 2026

規程要領のRAGのチューニングについて

招待済み 鳥居 萩 大橋敏明 田仲 将人

添付ファイル 規程要領のRAGのチューニングについて

会議の記録 文字起こし (一部の録画は利用できません)

概要

システムアップデート後の回答品質低下の原因を分析し、検索範囲の絞り込みを軸とする改善策を決定した。

モデル変更による現状分析

大規模言語モデル変更により回答の質は向上したが、RAG機能における不適切な参照や回答の欠落が確認された。表形式データに対する認識不足も顕在化した。

不具合の原因と改善策

海外ドキュメントの誤参照は検索範囲の広さが要因であり、GPU負荷によるリソース競合も品質低下に影響している可能性がある。

検索精度の改善方針

ユーザーが検索カテゴリを選択できるUI変更による範囲限定策を決定した。今後はプロンプト調整を含めた改善案を再検討する。

この要約を評価する: [役に立った](#) または [役に立たない](#)

次のステップ

- [大橋敏明] RAG改善フィードバック: フィードバックデータをアップロードしRAGの回答精度を向上させる。Excelを用いて一括でフィードバック情報を登録する。
- [グループ] UI設計の検討: 検索範囲を国内または海外に絞り込むための選択ボタンを導入する。ユーザー側でカテゴリーを選択しRAGの検索精度を調整する設計を検討する。
- [Souta Doi] GPU負荷調査: 回答精度の低下と関連する可能性があるGPUの負荷状況を内部で調査する。リソース使用率とリクエスト処理の関係を確認する。
- [Souta Doi] アプリフローの提示: アプリケーションのフローに関するサンプルを作成し、提供する。
- [大橋敏明] プロンプトの共有: 現在使用している規定容量のグループプロンプトをSouta Doiに送付する。
- [Souta Doi] プロンプト検証: 送付されたプロンプトとデフォルト設定との差分を確認し、精度の向上策を検討する。
- [鳥居萩] サンプルデータ作成: 決済権限表のフォーマットイメージをマスクした状態で作成し、Souta Doiに送付する。
- [Souta Doi] プロンプト調整案の検討: サンプルデータを使用して決済権限表向けのプロンプト調整案を検証する。

詳細

- システムアップデートと現状の評価: 大橋敏明は、5月1日に大規模言語モデル(LLM)を変更したことで、回答の質が全体的に向上したと報告しました。しかし、検索拡張生成(RAG)機能において特定の課題が確認されているため、今回のミーティングでその詳細な検討を行うこととなりました ([00:00:00](#))。
- **RAG**検索における課題パターン1(無関係なドキュメントの参照): 鳥居萩は、現状の課題として3つのパターンを挙げました。1つ目は、本来不要な海外関連のドキュメントが優先的に参照され、回答の精度が低下するケースです。例えば、グループ作成の手続きを問う際、無関係な海外個人所得税に関する資料が参照されるという事象が報告されました ([00:10:13](#))。
- **RAG**検索における課題パターン2(回答の欠落・不足): 2つ目のパターンとして、以前は回答できていた内容が、新モデルへの移行後に回答できなくなったり、内容が極端に簡素化されたりするケースが挙げられました。必要な情報の絞り込みが完全一致しないと、AIが回答を放棄する傾向が見られます ([00:11:31](#))。

- **RAG検索における課題パターン3**(表形式情報の誤解釈): 3つ目のパターンは、社内の権限表など、縦横で構成された表形式のデータをAIが正しく認識できないという問題です。AIが表の構造は理解できても、特定の契約金額やレンジに対する回答を誤るケースがあることが指摘されました ([00:12:59](#))。
- 過去の経緯と海外ドキュメント優先の問題: 大橋敏明と田中将人は、海外の資料が優先される問題は昨年末から確認されていた事象であり、田中将人はユーザーからの問い合わせでもこの傾向が見られると補足しました ([00:15:44](#)) ([00:27:55](#))。Souta Doilは、管理画面の利用履歴を通じて、海外関連の契約書や税務資料が、本来国内の契約内容を確認したい場合にも頻繁に参照されていることを確認しました ([00:18:49](#))。
- リトリバー(検索エンジン)の仕組みと改善策: Souta Doilは、LLMは検索エンジンが取得したドキュメントを根拠にするため、現在のリトリバーの調整が必要であると説明しました ([00:20:12](#))。具体的な改善策として、ユーザーからのフィードバック情報の蓄積や、データの検索範囲を絞り込む手法が提案されました ([00:22:55](#))。
- GPU負荷とシステムパフォーマンス: 田中将人は、回答精度の極端な低下について、GPUの負荷が影響しているのではないかと懸念を示しました ([00:29:06](#))。Souta Doilは、メモリ不足を回避するための制御を行っており、最大128kトークンまでのプロンプトを許容しているものの、同時使用時のリソース競合が回答品質に影響を与える可能性を否定できないと回答しました ([00:30:13](#))。
- 海外ドキュメントが優先される要因の分析: 鳥居萩は、海外の個人所得税に関する資料が、タイトルや文中に「契約」というキーワードが含まれるというだけで優先されている可能性を指摘しました。また、全体のドキュメントの中で当該資料が占める割合が非常に小さいにもかかわらず優先される理由が不明であると論じました ([00:31:48](#))。
- ユーザーインターフェースによる検索範囲の絞り込み: Souta Doilは、根本的な検索精度の改善策として、ユーザーが入力時に「国内」か「海外」などのカテゴリを選択できる仕組み(UIの変更)を提案しました。これにより、検索範囲を限定し、よりの確な根拠ドキュメントを抽出できるようになります ([00:34:12](#)) ([00:37:21](#))。
- フィードバック機能の活用と限界: Souta Doilは、検索制度を高めるために、管理画面からのフィードバック登録(Excelアップロードを含む)が有効であると説明しました。ただし、フィードバックはアプリ全体のリトリバーに作用するため、設定には注意が必要であると伝えました ([00:35:48](#)) ([00:40:14](#))。
- 権限表の誤解釈に対するアプローチ: パターン3の権限表の誤解釈に対しては、プロンプトの調整や決済権限表に特化した検索導線を作ることが有効であるとSouta Doilは示唆しました。鳥居萩は、分析のために適切な権限表のサンプルテンプレートを提供することに同意しました ([00:54:47](#)) ([01:04:40](#))。

- 回答欠落に対するプロンプトの調整: パターン2の「回答できなくなる」問題について、Souta Doiはモデルが不正確な情報を防ごうとする傾向があるため、プロンプトを調整して回答の柔軟性を高める手法を提案しました ([00:57:27](#))。
- 次なるステップとプロンプト分析: 今後の進め方として、大橋敏明は現在適用されているプロンプトの設定をSouta Doiに共有することとなりました。Souta Doiは、それを分析し、デフォルト設定との差異を確認した上で再提案を行う予定です。その後、メールでのやり取りを経て再度ミーティングを行うことが決定しました ([01:01:52](#))。

Gemini が生成したメモの内容の正確性をご確認ください。 [Gemini によるメモ作成のヒントや仕組み](#)

これらのメモの品質はいかがでしたか？ [簡単なアンケート](#)で、メモがニーズに合っていたかどうかなど、フィードバックをお寄せください。